Comment la Data Science peut améliorer la décision de crédit ?

Modélisation par réseaux de neurones sur le Credit Risk Dataset

Yannick ASSI

Data Management & Data Mining

Février 2026

uco

IMA
Institut de Mathématiques Appliquées

Contexte & enjeu

- La prédiction du risque de défaut est un enjeu majeur pour les institutions financières.
- Les exigences réglementaires (Bâle, Solvabilité II) et la croissance des données renforcent le besoin de modèles robustes permettant de pouvoir anticiper ce risque.
- Objectif opérationnel : **mieux discriminer les emprunteurs à risque** pour soutenir la décision (octroi / pricing / suivi portefeuille).

Question : Peut-on prédire la variable `loan_status` , qui indique si un prêt est sain ou en défaut, afin d'améliorer la décision d'octroi de crédit ?

Objectif de l'étude

1. Structurer et préparer le *Credit Risk Dataset*: `https://www.kaggle.com/datasets/laotse/credit-risk-dataset`
2. Construire un modèle capable de prédire un défaut.
3. Évaluer la performance sur un jeu test (données jamais vues).
4. Interpréter les résultats pour un usage métier.

Données : Credit Risk Dataset

Variable cible : `loan_status` (0 = non défaut, 1 = défaut)

Quelles informations sont utilisées :

- Profil : l'âge et le revenu du client
- Prêt : le montant et le taux du prêt
- l'Historique du crédit

Aperçu des données (extrait)

- Un jeu de données comportant **32 581** observations et **12** variables
- Variable Cible : `loan_status` (0 = non défaut, 1 = défaut)

age	income	home	emp_len	loan_amnt	int_rate	status
22	59 000	RENT	123	35 000	16.02	1
21	9 600	OWN	5	1 000	11.14	0
25	9 600	MORTGAGE	1	5 500	12.87	1
23	65 500	RENT	4	35 000	15.23	1
24	54 400	RENT	8	35 000	14.27	1
21	9 900	OWN	2	2 500	7.14	1

Préparation des données (Data Management)

- Une imputation par la moyenne des variables comportant des données manquantes (ex variables : `person_emp_length`, `loan_int_rate`)
- Encodage binaire de variables catégorielles
- Découpage : **80% train / 20% test** (26 065 / 6 516 obs.)

Résultat : un dataset exploitable pour la prédiction

Méthodologie : Réseau de neurones multi-perceptron (MLP)

Approche : classification supervisée (binaire)

Modèle retenu : Réseau de neurones multi-perceptron

Comment fonctionne le modèle ?

- Il reçoit les informations du client
- Il analyse les relations complexes entre ces informations
- Il produit un score entre 0 et 1 (0 = Faible risque , 1 = Risque élevé)

Plus techniquement le modèle est constitué :

- Couche d'entrée : comportant nos variables explicatives
- Couche cachée : activation par la fonction sigmoïde
- Sortie : 1 neurone = **probabilité de défaut**

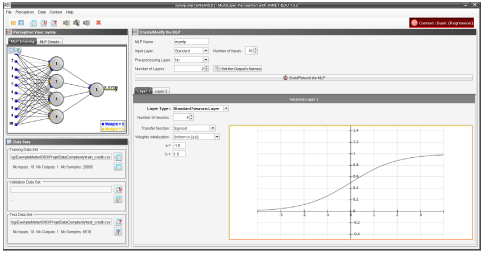
Architecture du réseau

Structure du modèle :

- 10 neurones en couche d'entrée
- 1 couche cachée : **4 neurones**
- 1 neurone de sortie
- Architecture globale : **10 - 4 - 1**

Fonction d'activation :

- Sigmoïde
- Sortie entre 0 et 1
- Interprétation : probabilité de défaut

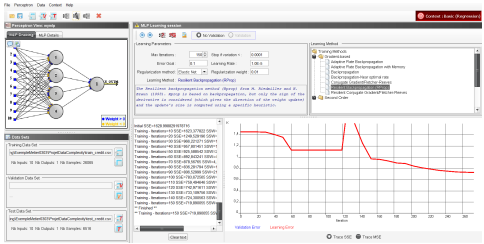


Méthode d'apprentissage :

- Resilient Backpropagation (RProp)
- Maximum : 150 itérations
- Régularisation : Elastic Net (0.01)

Évolution de l'erreur (Sum of Squared Errors) :

- SSE initial 1628
- SSE final 719
- Convergence progressive

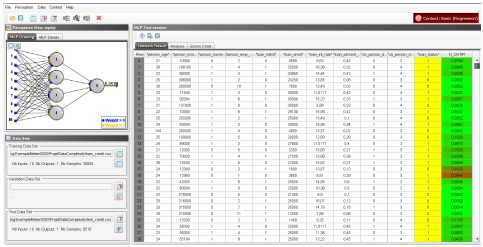


L'erreur diminue progressivement entre le début et la fin de l'entraînement. Le modèle apprend correctement, et améliore progressivement ses performances.

Résultats sur données test

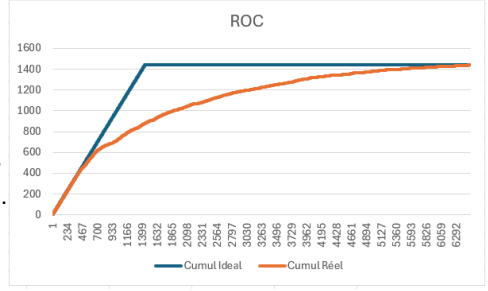
Performance globale :

- Chaque client reçoit un score de probabilité de défaut (entre 0 et 1).
- En fonction d'un seuil choisi, le modèle décide si le dossier est classé "défaut" ou "non défaut" .
- La majorité des dossiers sont correctement classés (86 %).



Pouvoir discriminant :

Plus la courbe est au-dessus de la diagonale, plus le modèle est performant pour détecter les risques sans bloquer inutilement de bons clients.



Conclusion : Apports métier du projet

Apports en gestion du risque :

- Amélioration de la détection des emprunteurs à risque
- Outil d'aide à la décision pour l'octroi de crédit
- Meilleure anticipation des défauts potentiels

Apports opérationnels :

- Production d'un score probabiliste exploitable
- Ajustement dynamique du seuil selon l'appétence au risque
- Soutien au pilotage et au suivi du portefeuille

Apports stratégiques :

- Optimisation du couple rentabilité / risque
- Réduction des pertes liées aux défauts
- Contribution à la conformité réglementaire (Bâle, Solvabilité II)